

```

# PROJET FINAL
# Auteur: Ronnie Liu
# Date: Mercredi 27 juillet 2021
# Objet: Fichier R pour QUESTIONS 3 et 4
n <- 100
phi <- 0.6
theta <- 0.9

#####
# a) Fonctions pour calculer les fonctions d'auto-corrélation

# Voir la démarche théorique de l'obtention des fonctions d'auto-corrélation
# pour chaque processus (p.13).


rho_1 <- ((phi+theta)*(1+phi*theta))/(1+2*phi*theta+theta^2)
# Pour le modèle ARMA(1,1):
# | = 1 si k = 0
# rho_k |
# | = phi^(k-1)*rho_1 sinon

# Pour le modèle AR(1):
# | = 1 si k = 0
# rho_k |
# | = phi^|k| sinon

# Pour le modèle MA(1):
# | = 1 si k = 0
# rho_k | = theta/(1+theta^2) si k = +/- 1
# | = 0 sinon

#####
# b) Traçage des ACF des trois séries

```



```

# Capacités de diagnostic pour chaque processus:
# Tous les processus sont inversibles et stationnaires dans cette question
# (voir 3a).

# Processus  $X_t$ : ARMA(1,1):
# 1. ACF: Décroissance exponentielle moins rapide que celle d'un modèle AR(1).
# 2. PACF: Décroissance exponentielle aussi, donc nombre infini de pics.
# Bref, détecter s'il y a un nombre infini de pics dans les deux graphiques
# d'auto-corrélation.




# Processus  $Y_t$ : ARMA(1,0) ou AR(1):
# 1. ACF: Décroissance exponentielle plus rapide que celle d'un ARMA(1,1).
# 2. PACF: Présence d'un seul pic significatif.
# Bref, ACF avec nombre infini de pics qui décroît et PACF avec un seul pic.

# Processus  $Z_t$ : ARMA(0,1) ou MA(1):
# 1. ACF: Présence d'un seul pic significatif. On voit qu'après le 2e délai,
# la valeur d'auto-corrélation devient nulle.
# 2. PACF: Décroissance exponentielle quant à la longueur des pics.
# Bref, ACF avec un seul pic et PACF avec nombre infini de pics qui décroît.

# En conclusion, si on se fie uniquement des graphiques d'ACF:
# ARMA(1,1): décroissance exponentielle
# AR(1): décroissance exponentielle plus rapide qu'ARMA(1,1)
# MA(1): valeurs non nulles dans les délais  $k = \{0,1\}$  seulement.

#####
# c) ACF Échantillonnale des séries générées et comparaison aux valeurs théo.

```



```
## [1] "RÉSULTATS POUR ARMA(1,1)"
```

EXPÉRIMENTALE

```
##
```


```
## Autocorrelations of series 'Xt', by lag
```

```
##
```

```
##      0      1      2      3      4      5      6      7      8      9     10
## 1.000  0.814  0.522  0.343  0.218  0.106  0.011 -0.046 -0.072 -0.105 -0.159
##     11     12     13     14     15     16     17     18     19     20     21
## -0.219 -0.266 -0.280 -0.266 -0.228 -0.198 -0.197 -0.207 -0.174 -0.092 -0.017
##     22     23     24     25     26     27     28     29     30
##  0.011 -0.008 -0.019 -0.039 -0.104 -0.130 -0.078 -0.001  0.050
```

THÉORIQUE

```
## [1] 1.000 0.799 0.480 0.288 0.173 0.104 0.062 0.037 0.022 0.013 0.008 0.005
## [13] 0.003 0.002 0.001 0.001 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## [25] 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
```



```
## [1] "RÉSULTATS POUR AR(1)"
```

EXPÉRIMENTALE

```
##
```


```
## Autocorrelations of series 'Yt', by lag
```

```
##
```

```
##      0      1      2      3      4      5      6      7      8      9     10
## 1.000  0.646  0.404  0.281  0.186  0.097  0.001 -0.060 -0.051 -0.087 -0.128
##     11     12     13     14     15     16     17     18     19     20     21
## -0.174 -0.224 -0.229 -0.231 -0.194 -0.144 -0.155 -0.177 -0.168 -0.064 -0.006
##     22     23     24     25     26     27     28     29     30
##  0.042 -0.019 -0.023 -0.004 -0.095 -0.146 -0.062 -0.015  0.046
```

THÉORIQUE

```
## [1] 1.000 0.600 0.360 0.216 0.130 0.078 0.047 0.028 0.017 0.010 0.006 0.004
## [13] 0.002 0.001 0.001 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## [25] 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
```



```
## [1] "RÉSULTATS POUR MA(1)"
```

EXPÉRIMENTALE

```
##
```


```
## Autocorrelations of series 'Zt', by lag
```

```
##
```

	0	1	2	3	4	5	6	7	8	9	10
##	1.000	0.495	0.035	0.066	0.094	0.085	-0.053	-0.094	0.013	0.046	-0.005
	11	12	13	14	15	16	17	18	19	20	21
##	-0.054	-0.054	-0.029	-0.073	-0.131	-0.108	-0.092	-0.177	-0.213	-0.110	0.013
	22	23	24	25	26	27	28	29	30		
##	0.063	-0.006	0.008	0.058	-0.061	-0.151	-0.105	-0.066	-0.014		

THÉORIQUE



```
## [1] 1.000 0.497 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## [13] 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## [25] 0.000 0.000 0.000 0.000 0.000 0.000 0.000
```





Les calculs théoriques représentent quand même les données expérimentales
 # à l'exception des derniers délais. Cela est causé par le fait qu'il n'y a pas
 # assez de données. Si par exemple $n = 10000$, on verra que les courbes
 # théoriques et expérimentales sont exactement identiques.

 # d) ACF, PACF, comparaisons et conclusion



Modèle ARMA(1,1)
`library(astsa)`
`acf2(Xt, max.lag=30)`
 # ACF: Nombre infini d'ACF
 # PACF: Nombre infini de PACF



Modèle AR(1)
`acf2(Yt, max.lag=30)`
 # ACF: Nombre infini d'ACF (décroiss
 qu'ARMA(1,1))
 # PACF: Nombre fini (un seul pic)




Modèle MA(1)
`acf2(Zt, max.lag = 30)`
 # ACF: Nombre fini (un seul pic)
 # PACF: Nombre infini de PACF



En conclusion, toutes les observations
 confirment les résultats
 # d'identification des modèles ARMA vus en
 classe.

EXERCICE 4

```
#####  
# ÉTAPES PRÉLIMINAIRES POUR L'ANALYSE DES DONNÉES  
# 1) CUEILLETTE D'INFORMATIONS  
  
# Les données sont tirées du site: https://www150.statcan.gc.ca/n1/fr/type/donnees  
# Quelques informations pertinentes par rapport aux données cueillies:  
  
# Numéro d'identification: 24-10-0002-01 (anciennement CANSIM 427-0002)  
# Nom d'étude: Nombre de véhicules voyageant entre Le Canada et Les États-Unis  
# (section: Total des véhicules entrant au Canada)  
# Période considérée: Janvier 2009 - Avril 2018  
  
# On veut étudier Le nombre total des véhicules entrant au Canada entre janvier  
# 2009 et avril 2018. Étant donné qu'on reçoit des millions de véhicules par  
# mois, l'analyse sera abordée selon les données recueillies, mais divisées par  
# un million afin de travailler avec des nombres plus petits. Les conclusions  
# demeurent identiques; Le but est uniquement de faciliter la tâche à visualiser  
# Les résultats en réduisant le nombre de chiffres dans une donnée.  
  
# Nous avons créé un fichier nommé Data_Q4.csv qui contient toutes les données  
# nécessaires. L'annexe A montrera le contenu de ce dernier.  
  
data <- read.csv('Data_Q4.csv', sep=';')  
mois <- data$ï..Mois  
y <- data$Qty  
y_new <- data$Qty/1000000  
  
write.csv(cbind(mois, y_new), 'Data_Q4_modified.csv')  
data <- read.csv('Data_Q4_modified.csv', sep=',')  
y <- data$y_new  
  
# Premier aperçu des données recueillies
```



```
# Commentaires: La série chronologique est saisonnière de fréquence mensuelle.  
# On peut voir que chaque année, le mois qui a le plus de véhicules qui entre  
# au Canada est le mois d'août, ce qui a du sens étant donné que c'est la  
# période des vacances.
```

```
# Selon le graphique, nous n'étions pas certain si la tendance est linéaire  
# dans cette série chronologique, mais il y a une tendance peu importe.  
# Nous avons essayé plusieurs tentatives pour éliminer cette tendance:  
# la racine carrée, l'inverse, le logarithmique, mais la tendance demeure  
# présente. L'hypothèse sera de faire une différenciation deux fois puisqu'on  
# voit une tendance qui ressemble à une fonction quadratique. Ensuite,  
# on fait une différenciation saisonnière afin que la série soit plus  
# stationnaire.
```


```
# 2) AJUSTEMENT DE CETTE SÉRIE AVEC LES MÉTHODES ARIMA
```

```
# Ajustement 1: Diviser les données par un million pour simplifier la tâche  
# d'analyse  
# Ajustement 2: Différenciation première (et double?) pour éliminer la tendance  
# Ajustement 3: Différenciation saisonnière où  $s = 12$  mois
```

```
# 3) NOMBRE D'OBSERVATIONS
```

```
# Troncage des 12 dernières données, afin de faire l'analyse avec les 110  
# premières observations
```


```
n <- 100  
t <- seq(1,100,1)  
y <- data$y_new[-seq(101, 112,1)]
```




```
#####
# a) Transformation de la série

# En faisant plusieurs expérimentations, on rejette notre hypothèse initiale,
# c'est-à-dire de faire deux différenciations non saisonnières.
# Avec une seule différenciation, on observe que les données semblent plus
# "stationnaires" et visuellement, nous avons éliminé la tendance.

# dy: données brutes différenciées une seule fois
# ddy: dy différenciées de façon saisonnière une seule fois
```



```
# On observe que la présence d'un motif pour chaque mois, donc il faut
# l'éliminer à l'aide de la différenciation saisonnière afin que les données
# semblent être stationnaires.
```




```
# Conclusion, on prend les données brutes qui sont différenciées
# de façon linéaire et saisonnière une fois chacune.
```



```
#####
# b) Les ordres du modèle choisi

# Commençons par analyser les ACF et les PACF du modèle
acf2(ddy, max.lag=50)
```



```
# COMPOSANTE NON SAISONNIÈRE (délais faibles entre 1 et 11):
# ACF: Observation d'un seul pic (ou) décroissance exponentielle des auto-
#       corrélations
# PACF: Observation d'un seul pic aussi (ou) décroissance exponentielle des
#       auto-corrélations

# Nous sommes certains la valeur de p ou de q ne dépassera pas de 1, donc nous
# avons trois modèles possibles à tester:
# ARIMA(1,1,0) - ARIMA(0,1,1) - ARIMA(1,1,1)

# COMPOSANTE SAISONNIÈRE (délais 12, 24, 36...):
# Dans le graphique des ACF et des PACF, c'est la partie la plus compliquée
# à remarquer puisque plusieurs phénomènes peuvent y arriver.

# Voici quelques hypothèses par rapport à la composante saisonnière du modèle:
# Le délai 12 dans ACF n'atteint pas vraiment la ligne "bleue", mais est proche,
# tandis que ce dernier n'est pas du tout atteint dans PACF.

# 1. Il se peut que le délai 12 est ignoré dans les deux graphiques, donc ça va
#    être ARIMA(0,1,0)_12.
# 2. Sinon, puisque le délai 12 a une auto-corrélation plus élevée dans ACF, il
#    se peut que ça soit un pic à considérer, donc ARIMA(0,1,1)_12 ou
#    ARIMA(1,1,1)_12 (peut considérer comme une décroissance exponentielle
#    dans le graphique ACF).
```

```

# Noter que Les valeurs à côté de La ligne "sarima" sont les valeurs
# de Log(vraisemblance) correspondante.

# Test 1: Avec ARMA(1,1) non saisonnier (modèles 1 à 3)
1. sarima(y, 1,1,1, 0,1,0, 12)          #92.00 -- non-significatif
2. sarima(y, 1,1,1, 0,1,1, 12)          #93.88 -- non-significatif
3. sarima(y, 1,1,1, 1,1,1, 12)          #94.82 -- non-significatif

# Test 2: Avec AR(1) non saisonnier (modèles 4 à 6)
4. sarima(y, 1,1,0, 0,1,0, 12)          #91.93 -- significatif
5. sarima(y, 1,1,0, 0,1,1, 12)          #93.76 -- significatif
6. sarima(y, 1,1,0, 1,1,1, 12)          #94.76 -- non significatif

# Test 3: Avec MA(1) non saisonnier (modèles 7 à 9)
7. sarima(y, 0,1,1, 0,1,0, 12)          #91.96 -- significatif
8. sarima(y, 0,1,1, 0,1,1, 12)          #93.86 -- significatif
9. sarima(y, 0,1,1, 1,1,1, 12)          #94.80 -- non-significatif

# Dès Le départ Les modèles 1, 2, 3, 6 et 9 ne sont pas considérées puisqu'il
# existe des paramètres dont la p-valeur n'est pas du tout significative.


# Il reste à choisir un modèle parmi 4, 5, 7 et 8.
# La valeur Log(vraisemblance) la plus élevée (AIC la moins élevée) est le
# modèle 8, donc on choisira ce dernier et l'analyser pour confirmer si
# c'est un bon choix.

# Modèle choisi: ARIMA(0,1,1) x (0,1,1)_12

#####
# c) Statistiques diagnostics et autres diagnostics
# Observations des tests et des résidus

# MODÈLE ARIMA(0,1,1) X (0,1,1)_12
sarima(y, 0,1,1, 0,1,1, 12)
## converged

```



```

## $fit
##
## Call:
## arima(x = xdata, order = c(p, d, q), seasonal = list(order = c(P, D, Q), period =
##      S),
##      include.mean = !no.constant, transform.pars = trans, fixed = fixed,
##      optim.control = list(trace = trc,
##      REPORT = 1, reltol = tol))
##
## Coefficients:
##          ma1      sma1
##      -0.3226  -0.3164
## s.e.   0.1037   0.1554
##
## sigma^2 estimated as 0.006662:  Log Likelihood = 93.86, aic = -181.72
##
## $degrees_of_freedom
## [1] 85
##
## $ttable
##      Estimate      SE t.value p.value
## ma1  -0.3226 0.1037 -3.1100 0.0025
## sma1 -0.3164 0.1554 -2.0362 0.0448
##
## $AIC
## [1] -1.854237
##
## $AICc
## [1] -1.852948
##
## $BIC
## [1] -1.77875

```

*# AIC de -181.72 qui est le plus petit parmi les autres modèles testés.
Log Likelihood de 93.86.*

*# Standardized Residuals: Les résidus sont majoritairement entre -3 et 3 comme
dans la loi normale centrée réduite (sauf au temps t=80 où ça dépasse un peu
-3). On peut dire que les résidus se comportent selon la loi normale.*

*# ACF of Residuals: Aucune présence d'auto-corrélation entre les résidus, donc
le modèle est accepté.*

*# Ici, les résidus sont selon la loi normale de façon majoritaire. On peut
voir un peu de déviations lors des extrémités, mais la plupart des données
demeurent "normales".*

*# Ljung-Box: Les p-valeurs se trouvent au-dessus de la ligne bleue, donc on ne
rejette pas l'hypothèse nulle pour tous les délais. Donc, on peut prendre
ce modèle pour faire des prévisions des 12 prochains mois.*

```
# DISCUSSION DES P-VALEURS DES ESTIMATEURS ET DE LA VALEUR ALPHA:
# IL est vrai que les estimateurs ont des p-valeurs significatives, mais en
# ce qui concerne de sma1: la p-valeur est 0.0448, ce qui est très proche de 5%.

# Par conséquent, Le modèle choisi va dépendre de l'erreur du type I tolérée.
# Si par exemple on choisit un modèle avec un alpha de 2.5%, ce modèle ne sera
# plus valide. Dans ce cas-ci, on prendra le modèle 7 (car le modèle 5 a aussi
# un estimateur avec une p-valeur proche de 5%) qui est ARIMA(0,1,1)x(0,1,0)_12.

# Bref, ici, alpha = 5% et c'est pour cela qu'on prend le modèle choisi en b).
# Cependant, le modèle 5 doit être réservé si jamais on veut des prévisions plus
# précises (alpha < 5%).

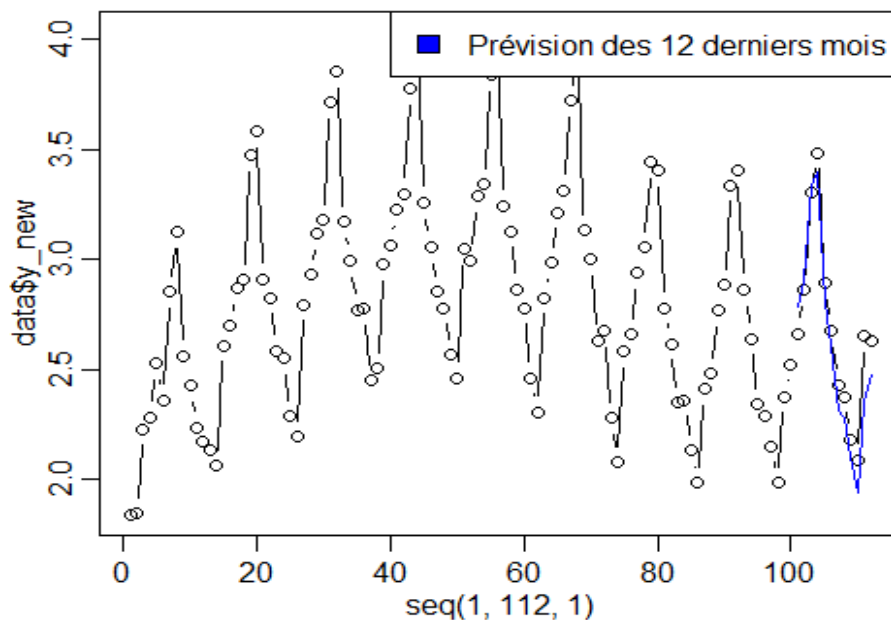
#####
# d) Performance prévisionnelle

# Vraies valeurs des 12 derniers mois
last_y <- data$y_new[seq(101,112,1)]

# Valeurs prédites des 12 derniers mois
predict_model <- sarima.for(y, 12, 0,1,1, 0,1,1, 12)
predict_y <- predict_model$pred

# EQMP
EQMP <- mean((predict_y - last_y)^2)
EQMP
## [1] 0.01698084

# Ligne bleue: Les prévisions
# Ligne noire: Les données brutes
```




```
# Nous avons une EQMP de 0.01698084, ce qui est proche de zéro. Cela montre
# que Le modèle choisi prédit assez bien les 12 prochains mois.
```

```
#####
# e) Intervalles de prévision

# En se servant de la formule  $y_{\text{hat}} \pm 1.95 \cdot se$ , on obtient les intervalles
# de prévision suivants pour les 12 dernières données
borneInf <- predict_y - 1.96*predict_model$se
borneSup <- predict_y + 1.96*predict_model$se

cbind(borneInf, predict_y, borneSup)
## Time Series:
## Start = 101
## End = 112
## Frequency = 1
##      borneInf predict_y borneSup
## 101 2.624813  2.784791 2.944768
## 102 2.704049  2.897273 3.090497
## 103 3.112857  3.334393 3.555929
## 104 3.145944  3.392562 3.639181
## 105 2.540047  2.809423 3.078799
## 106 2.318592  2.608947 2.899302
## 107 2.005358  2.315275 2.625193
## 108 1.951728  2.280045 2.608361
## 109 1.756602  2.102340 2.448077
## 110 1.577291  1.939613 2.301934
## 111 1.972231  2.350411 2.728590
## 112 2.081813  2.475211 2.868609
#####
# f) Représentation graphique des prévisions

# Les lignes violettes représentent les bornes inférieures et supérieures
# des intervalles de prévisions.
sarima.for(y, 12, 0,1,1, 0,1,1, 12)
```



```

# Modèle choisi: ARIMA(0,1,1) X (0,1,1)12
#  $(1 - B^{12})(1 - B) Y_t = (1 - 0.3226B)(1 - 0.3164B^{12}) e_t$ 
# ou
#  $Y_t = Y_{t-1} + Y_{t-12} - Y_{t-13} + e_t - 0.3226 e_{t-1} - 0.3164 e_{t-12} + 0.10207064 e_{t-13}$ 
# où  $e = \text{epsilon}$ 

```